

BÁO CÁO TIẾN ĐỘ TUẦN 1

Nghiên cứu cơ bản Deep Reinforcement Learning

Presenter: Tran Dinh Duy Ngo

Title: Internship

Mục tiêu & Trạng thái tuần 1

Mục tiêu

Tìm hiểu cơ bản về Deep Reinforcement Learning

Trạng thái hiện tại

Đạt mục tiêu tuần 1: đã nắm khung lý thuyết và có nền tảng để bước sang Deep Q-Learning.


Trạng thái: chuẩn bị thiết lập baseline DQN trong tuần 2.

Nội dung đã nắm rõ

- Vòng lặp cơ bản trong RL: state $\rightarrow$ action $\rightarrow$ reward $\rightarrow$ policy.
- Hiểu rõ bản chất và cơ chế hoạt động của Q-learning, sử dụng Q-table.
- Đã áp dụng Q-learning (Q-table) vào 2 môi trường đơn giản: CliffWalking-v1 và [ns3-gym](#) (môi trường custom được dựng sẵn từ repo của cộng đồng).
- Đã đủ vững để có thể chuyển tiếp sang nghiên cứu DQN: thay Q-table trong Q-learning bằng Neural Network.

Cốt lõi của DRL

Vòng lặp tương tác Agent — Environment



Q-update: $Q(s,a) \leftarrow Q(s,a) + \alpha [r + \gamma \max_{a'} Q(s',a') - Q(s,a)]$

Trong đó:


- α là learning rate: độ lớn gradient mà ta muốn cập nhật cho Q-value
- r là reward: phần thưởng (tốt hoặc xấu) môi trường trả về cho agent.
- γ là gamma: hệ số discount, xác định tầm quan trọng của các reward trong tương lai.

Ý nghĩa trong tuần 1

- Q-learning học giá trị $Q(s,a)$ cho từng cặp state–action.
- Epsilon-greedy cân bằng exploration và exploitation.
- Q-table phù hợp bài toán nhỏ, state rời rạc.
- Q-table không thể áp dụng cho các bài toán có state là liên tục, khi đó không thể construct bảng được, vì sẽ cần vô số dòng đại diện cho từng state liên tục.


Các môi trường đã thử nghiệm

1) CliffWalking-v1: benchmark nhỏ, dễ kiểm chứng



- Tổng 48 ô, đường đi ngắn nhất là 13 ô → best reward là (+/-)13.

2) ns3-gym: hướng áp dụng cho mô phỏng mạng



- Có liên quan đến định hướng Viettel High Tech: bài toán về network/system simulation.
- Quan sát được rằng việc rời rạc hóa các tín hiệu liên tục quá mang tính khách quan (vì Q-table cần dữ liệu state rời rạc, nên phải rời rạc hóa tín hiệu đầu vào).
- Cần chuyển sang DQN để xử lý state space lớn hơn (liên tục) và đặc trưng phức tạp hơn.

Tại sao DQN lại tốt hơn Q-table?


Giới hạn của Q-table

State/action space lớn $\rightarrow$ Q-table tăng kích thước nhanh (không giới hạn), khó lưu trữ và khó generalize.

Không tận dụng tốt dữ liệu liên tục.

Khó mở rộng cho môi trường mô phỏng mạng có nhiều tham số động và liên tục.

DQN thay thế Q-table bằng neural network



Core components cần nắm trong tuần 2:

Experience Replay


Target Network

Loss MSE/Huber

Exploration

Rút ra được: Q-table giúp hiểu cơ chế học; DQN là bước mở rộng cần thiết để xử lý bài toán thực tế hơn.

Kế hoạch tuần 2



Output mong muốn cuối tuần 2

- Code DQN baseline có log reward và biểu đồ hội tụ.
- Bảng so sánh: Q-learning tabular vs DQN về input, model, ưu/nhược điểm.
- Đề xuất 1 bài toán mô phỏng mạng phù hợp để thử trên ns3-gym.

Rủi ro / cần hỗ trợ

- Cần xác định use case mạng cụ thể để thiết kế reward hợp lý.
- Cần thống nhất metrics đánh giá: throughput, delay, packet loss, reward.

Nguồn tham khảo: ns3-gym GitHub/ns-3 app page; Gymnasium CliffWalking-v1 docs; Mnih et al., Nature 2015 DQN.

A word cloud featuring the phrase "Thank You" in numerous languages. The words are arranged in a circular pattern, with "THANK YOU" being the largest and most central. Other languages include Spanish (GRACIAS, ARIGATO), Arabic (SHUKRIYA, SHUKRIA), Hindi (DANKSCHEEN), and many others. The background is a light blue gradient with a subtle pattern of small white dots.